

Actividad: Neural ODEs sobre Datos Biológicos

Integrantes: Tomás Otero López, Juan Esteban Toro Soto [cite: 2]

Profesor: Carlos Manuel Orrego Franco [cite: 2]

Análisis Numérico – Universidad Nacional de Colombia [cite: 2]

24 de Mayo de 2026 [cite: 2]

1. Descripción del dataset

El dataset seleccionado corresponde a la base de datos de COVID-19 JHU, centrado en los nuevos casos diarios por país[cite: 4]. Las características principales son:

- **Número de trayectorias:** 178 [cite: 4]
- **Pasos de tiempo (longitud):** 400 [cite: 4]
- **Dimensiones de la observación:** 1 (Nuevos casos normalizados) [cite: 4]
- **Rango de valores:** $[-1,098, 7,928]$ [cite: 4]

Análisis Exploratorio: Al visualizar las trayectorias de diferentes países, se evidencia una tendencia general de crecimiento caracterizada por picos muy marcados que representan las distintas “olas” de contagio. Además, se observa ruido en la señal atribuible a las dinámicas reales de recolección de datos epidemiológicos (por ejemplo, retrasos de fin de semana). Las series temporales presentan un muestreo intrínsecamente irregular en su comportamiento dinámico.

2. Hiperparámetros elegidos y justificación

Se configuró la arquitectura y el entrenamiento con los siguientes parámetros[cite: 7, 8, 9, 10, 11, 12, 13]:

- **dim_latente (16):** Provee un equilibrio adecuado. Brinda suficiente capacidad al modelo para aprender interacciones ocultas complejas en la propagación del virus sin saturar excesivamente el espacio de parámetros, mitigando el riesgo de sobreajuste.
- **learning_rate (0.001):** Este valor es el estándar óptimo para el optimizador Adam, proporcionando un descenso de gradiente estable sin causar inestabilidades severas en el integrador numérico.

- **n_epochs (35):** Se determinó este número como un compromiso entre la convergencia de la función de pérdida y el alto costo computacional del solucionador RK4 empleado.
- **batch_size (32), dim_oculto_f (48), dim_oculto_enc (32), dim_oculto_dec (48):** Dimensiones estándar que permiten una capacidad de representación intermedia tanto en las redes recurrentes del encoder como en la red densa que define la dinámica continua.

3. Tabla de resultados RMSE

A continuación, se presentan las métricas de evaluación (Raíz del Error Cuadrático Medio) divididas en reconstrucción (rec) y extrapolación (ext) para diferentes densidades de observación[cite: 16].

Modelo	30 % rec	30 % ext	60 % rec	60 % ext	100 % rec	100 % ext	Params	Tiempo (s)
Método Clásico	0.0000	0.1142	0.0000	0.0866	0.0000	NaN	4	0.0
Neural ODE	0.4987	0.4998	0.4967	0.5036	0.4995	NaN	4,897	2730.7
Latent ODE	0.6023	0.6015	0.5999	0.6045	0.6017	NaN	9,281	3567.7

Cuadro 1: Resultados experimentales comparando el Método Clásico frente a enfoques basados en Neural ODEs[cite: 16].

4. Figuras

Figura 1: Exploración del dataset de COVID-19 JHU.

Figura 2: Comparación de modelos con un 60 % de datos observados.

Figura 3: Curvas de aprendizaje de Neural ODE y Latent ODE.

5. Respuestas a las preguntas de análisis

P1: ¿Con qué porcentaje de observaciones empieza a ganar la Neural ODE?

De acuerdo con los resultados experimentales documentados en la Tabla 1, la Neural ODE **no superó** al método clásico en ninguno de los porcentajes evaluados. El Método Clásico obtuvo un error sistemáticamente menor, especialmente destacado por un error de reconstrucción de 0,0000 en todas las pruebas.

P2: ¿Por qué el encoder RNN corre en orden inverso al tiempo?

El objetivo del encoder en una Latent ODE es procesar la secuencia temporal para estimar el estado latente inicial z_0 (el estado en $t = 0$). Las Redes Neuronales Recurrentes (RNN) tienden a “olvidar” la información inicial a medida que procesan secuencias largas. Al invertir el tiempo temporal $(t_N, t_{N-1}, \dots, t_0)$, el último dato ingresado a la red es precisamente t_0 , garantizando que la memoria de la red esté “fresca.”^{en} el instante clave que debe predecir, mitigando el problema del olvido a largo plazo.

P3: ¿Hubo algún resultado sorpresivo? ¿Por qué?

Fue particularmente sorpresivo que el Método Clásico superara a las redes ODE, logrando un RMSE de reconstrucción perfecto (0,0000) e índices de extrapolación considerablemente bajos (ej. 0,1142 con 30 % de datos). Esto se explica por dos fenómenos numéricos:

1. **Sobreajuste del método clásico:** El spline interpoló exactamente los puntos de entrenamiento asumiendo el ruido como señal verdadera. Por casualidad geométrica en este intervalo específico, su extensión polinómica no divergió masivamente en el test.
2. **Subajuste y debilidad estructural del integrador numérico:** La Neural ODE sufrió por falta de épocas para converger. Más críticamente, al forzar un paso fijo $h = t_{i+1} - t_i$ en un integrador RK4 sobre datos de muestreo irregular, los grandes vacíos temporales causaron saltos masivos que amplificaron el error de truncamiento global $\mathcal{O}(h^4)$, impidiendo que el método adjunto calculara gradientes precisos.

P4: ¿En qué tipo de problema NO recomendarían una Neural ODE?

Las Neural ODE no son recomendables en los siguientes escenarios:

- **Bases de datos sin tendencias globales compartidas:** Si cada trayectoria tiene dinámicas radicalmente distintas que no pueden ser descritas por un sistema continuo f_θ unificado.
- **Entornos de recursos computacionales limitados o tiempo real:** Las múltiples evaluaciones que exige el solucionador numérico por cada paso de tiempo hacen que su entrenamiento e inferencia sean extremadamente lentos (como lo demuestran los miles de segundos registrados en el experimento).
- **Sistemas de naturaleza estrictamente discreta:** Como el procesamiento de lenguaje natural tradicional, donde los métodos secuenciales estándar (Transformers/RNNs) son mucho más eficientes.

6. Conclusiones

Esta actividad práctica nos permitió contrastar la teoría matemática subyacente de las Redes Neuronales basadas en Ecuaciones Diferenciales Ordinarias (Neural ODEs) con los retos empíricos de su implementación numérica. Se evidenció cómo las limitantes de un solucionador clásico (RK4) frente a muestreos irregulares comprometen el cálculo de gradientes a través del método adjunto, derivando en subajustes. Al mismo tiempo, se observó claramente el comportamiento interpolador de los métodos clásicos (splines), los cuales pueden presentar cifras de error nulas en entrenamiento a costa de un severo sobreajuste a señales con alto nivel de ruido, como lo son las dinámicas epidemiológicas del COVID-19.